



Alpha 掘金系列之二十二

金融工程专题报告
证券研究报告

金融工程组

分析师：高智威（执业 S1130522110003）

gaozhiw@gjzq.com.cn

基于 GFlowNet 的低相关性量价因子挖掘策略

GFlowNet（生成流网络）原理介绍

因子挖掘一般指从行情、财务、另类数据里构造能解释或预测收益的特征（因子），再经检验、组合与风控后用于选股或择时；自动化因子挖掘则是在人工提出假设与写公式之外，用程序在大规模搜索空间里系统生成、变异、筛选因子，并与回测、稳健性检验流水线结合，减轻“拍脑袋”与重复劳动。

GFlowNet 是由 Yoshua Bengio 团队于 2023 年提出的新型生成模型，其核心是将对象生成过程建模为有向无环图中的“水流”过程，训练目标满足流量守恒定律，最终实现生成对象的概率与其奖励成正比。不同于遗传规划、强化学习等自动化因子挖掘的代表方法，它以“生成一群优秀的多元化公式”为核心目标，通过结构化学习实现“有策略的高效探索”，展现出优良的性质。

基于日频数据的因子挖掘与 RL 比较

我们基于日频量价数据，构建 GFlowNet 因子挖掘系统，训练采用更稳定的 Trajectory Balance (TB) 目标，通过采样轨迹、计算奖励与 TB 损失并反向传播更新模型参数完成训练。状态表示包含动作历史序列的 Transformer 编码及 3 个手工状态特征，动作空间涵盖算子、窗口、特征三类操作，表达式以 ExprNode 树结构组织并进行简化以降低重复。针对日频量价数据，我们给 GFlowNet 输入两套特征，第一套是原始 OHLCV（后复权）数据，第二套是对原始 OHLCV 进行无量纲相对特征处理后的数据，奖励设定为市值中性化后的 $abs(IC)$ 。

将其与基于 Transformer Actor-Critic 结构、PPO 算法的强化学习（RL）系统对比，发现 RL 虽训练初期 batch 平均奖励上升更快，但存在明显模式崩溃，batch 内因子相关性中位数升至 1，而 GFlowNet batch 内相关性中位数不到 0.04，多样性优势显著。

以 2018–2025 年为因子检验区间，观察基于原始 OHLCV 挖掘单因子表现，其整体表现良好，IC 均值的中位数达到 4.54%，最大值达到 8.56%，多头超额表现尚可，中位数为 3.47%；基于相对特征挖掘的因子表现更优，IC 均值中位数达 6.17%，最大值也达到了 9.40%，两类因子相关性均较低、复杂度可控，具备良好可解释性与应用价值。

基于分钟频数据的因子挖掘

对于分钟数据因子挖掘，我们采取简易处理方法：首先主要基于价格动量、波动、价位关系等 40 个指标，将日内分钟数据降为日频特征；后续复用日频挖掘框架，基于该 40 个特征进行搜索。

基于分钟频构造特征挖掘的单因子表现优异，IC 均值中位数达 5.83%，最大值 9.46%，多头超额收益中位数为 7.43%，较日频挖掘因子显著提升，因子相关性与复杂度均维持在较低水平。

将挖掘出的因子按照因子方向等权合成，基于相对特征挖掘出的因子收益情况比较一般，基于分钟频数据构造特征挖掘的因子 IC 和多空收益较好。风险暴露方面，单因子为对市值进行中性化后的因子值，合成之后，小市值和低波风格暴露依旧比较明显，基于相对特征挖掘的因子小市值暴露较低。多头暴露方面，中小市值的多头暴露比较明显，同时等权合成因子具有明显的价值风格暴露。

对现有 AI 模型的提升与指增策略

在前期工作《基于 Mamba2 模型的端到端选股框架》中，我们引入了新的 Mamba 模型进行深度学习建模，本报告在 GRU 和 Mamba 的基础上，添加 GFlowNet 挖掘出的 150 个因子，可以发现几乎所有指标都有一定的提升。

风险提示

- 1、以上结果通过历史数据统计、建模和测算完成，在政策、市场环境发生变化时模型存在时效的风险；
- 2、策略通过一定的假设通过历史数据回测得到，当交易成本提高或其他条件改变时，可能导致策略收益下降甚至出现亏损。



内容目录

一、GFlowNet（生成流网络）原理介绍.....	4
1.1 为什么需要 GFlowNet?	4
1.2 AlphaSAGE: GFlowNet 结合 RGCN 与多维度奖励用于因子挖掘	4
1.3 什么是 GFlowNet (Generative Flow Networks, 生成流网络)?	5
二、基于日频数据的因子挖掘与 RL 比较.....	7
2.1 训练目标与过程.....	7
2.2 状态表示、表达式与算子设计.....	7
2.3 特征、奖励设计与其它设定.....	8
2.4 与 PPO 强化学习的对比：低相关性优势显著.....	8
2.5 日频数据 GFlowNet 因子挖掘效果.....	10
三、基于分钟频数据的因子挖掘.....	12
3.1 分钟频数据 GFlowNet 因子挖掘效果.....	12
3.2 GFlowNet 挖掘因子等权合成果.....	14
四、对现有 AI 模型的提升与指增策略.....	17
总结.....	20
风险提示.....	20

图表目录

图表 1: GFlowNet vs 强化学习 (Reinforcement Learning, RL)	4
图表 2: GFlowNet vs 遗传规划 (Genetic Programming, GP)	4
图表 3: AlphaSAGE 模型结构图.....	5
图表 4: GFlowNet 基于 DAG 生成最终对象.....	5
图表 5: GFlowNet 迭代构建对象的过程.....	6
图表 6: 因子挖掘算子设计体系	8
图表 7: 原始 OHLCV 无量纲相对特征列表	8
图表 8: 强化学习损失函数与 batch 平均 reward.....	9
图表 9: GFlowNet 损失函数与 batch 平均 reward	9
图表 10: 强化学习 batch 内相关性水平	9
图表 11: GFlowNet batch 内相关性水平.....	9
图表 12: 基于原始 OHLCV 挖掘因子 IC 均值等统计指标	10
图表 13: 基于原始 OHLCV 挖掘因子 IC 分布	10
图表 14: 基于原始 OHLCV 挖掘因子 ICIR 分布	10
图表 15: 基于原始 OHLCV 挖掘因子截面时序相关性统计指标	10



图表 16: 基于原始 OHLCV 挖掘因子截面相关性	11
图表 17: 基于原始 OHLCV 挖掘因子时序相关性	11
图表 18: 基于原始 OHLCV 挖掘因子举例	11
图表 19: 基于原始 OHLCV 挖掘因子复杂度分布统计数据	11
图表 20: 基于原始 OHLCV 挖掘因子长度分布	12
图表 21: 基于相对特征挖掘因子 IC 均值等统计指标	12
图表 22: 基于相对特征挖掘因子 IC 分布	12
图表 23: 基于相对特征挖掘因子 ICIR 分布	12
图表 24: 基于分钟量价数据构造的日频特征列表	13
图表 25: 基于分钟频构造特征挖掘因子 IC 均值等统计指标	14
图表 26: 基于分钟频构造特征挖掘因子 IC 分布	14
图表 27: 基于分钟频构造特征挖掘因子 ICIR 分布	14
图表 28: GFlowNet 挖掘因子等权合成统计指标	14
图表 29: GFlowNet 挖掘因子等权合成超额净值	15
图表 30: GFlowNet 基于原始 OHLCV 挖掘因子截面 Barra 相关性	15
图表 31: GFlowNet 基于相对特征挖掘因子截面 Barra 相关性	16
图表 32: GFlowNet 基于分钟频构造特征挖掘因子截面 Barra 相关性	16
图表 33: GFlowNet 基于原始 OHLCV 挖掘因子多头暴露	17
图表 34: GFlowNet 基于相对特征挖掘因子多头暴露	17
图表 35: GFlowNet 基于分钟频构造特征挖掘因子多头暴露	17
图表 36: GRU+Mamba+GFlowNet 全 A 统计指标	18
图表 37: GRU+Mamba+GFlowNet 全 A 多头超额收益率	18
图表 38: 宽基指数增强统计数据	18
图表 39: 沪深 300 增强净值	19
图表 40: 沪深 300 增强分年度数据	19
图表 41: 中证 500 增强净值	19
图表 42: 中证 500 增强分年度数据	19
图表 43: 中证 1000 增强净值	19
图表 44: 中证 1000 增强分年度数据	19



一、GFlowNet（生成流网络）原理介绍

因子挖掘（Factor Mining）一般指从行情、财务、另类数据里构造能解释或预测收益的特征（因子），再经检验、组合与风控后用于选股或择时；自动化因子挖掘则是在人工提出假设与写公式之外，用程序在大规模搜索空间里系统生成、变异、筛选因子，并与回测、稳健性检验流水线结合，减轻“拍脑袋”与重复劳动。作为自动化因子挖掘的代表方法，遗传规划把因子表达式当作可进化的“程序树”，通过选择、交叉、变异在函数集与变量集上迭代，使适应度（如夏普、IC）较优的公式存活下来，适合探索非线性与复合结构。强化学习则把“造因子或调参”建模为序贯决策：智能体根据状态（如当前因子池、市场片段）采取动作（改公式、换参数、增删特征），环境用回测或代理目标给出奖励，从而在长期优化下学到策略或因子生成策略。

1.1 为什么需要 GFlowNet？

GFlowNet（Generative Flow Network，生成流网络）是最新提出的一种生成模型，其原理本文将在后续小节详细介绍，本节主要介绍它的特性，以及为什么天然适合于因子挖掘。

在目标导向上，不同于强化学习（RL）聚焦单一最优解的探索，它以“生成一群优秀的多元化公式”为核心目标，核心任务是生成组合型对象（例如分子结构、图、代码等），并使得生成某个对象 x 的概率与其对应的奖励（Reward）成正比，即： $P(x) \propto R(x)$ 。这极其契合多因子选股模型需要低相关性、高多样性 Alpha 池子的根本诉求。

图表1：GFlowNet vs 强化学习（Reinforcement Learning, RL）

对比维度	强化学习（RL）	生成流网络（GFlowNet）
优化目标	最大化预期奖励，寻找最优解： $\arg \max R(x)$	按照奖励大小的分布进行采样： $P(x) \propto R(x)$
探索机制	容易发生模式崩溃（Mode Collapse）。一旦找到几个极高收益的因子，策略就会收敛，反复生成相似的公式。	天生具备极强的多样性（Diversity）保证。能够广泛探索整个公式空间，发现不同流派的高收益因子。
因子相关性	挖掘出的因子高度同质化，特征重叠严重。	挖掘出的因子结构多样，相关性低，非常适合直接构建多因子组合（Alpha Pool）。

来源：国金证券研究所

在搜索效率上，相比遗传规划（GP）“盲目的演化搜索”模式，GFlowNet 通过结构化学习实现“有策略的高效探索”，大幅降低了庞大搜索空间中的无效消耗，提升了规律挖掘的精准度与效率。

图表2：GFlowNet vs 遗传规划（Genetic Programming, GP）

对比维度	遗传规划（GP）	生成流网络（GFlowNet）
底层驱动力	启发式/随机搜索。基于随机变异和交叉，缺乏对整个公式空间规律的“理解”。往往是在局部进行试错。	神经网络泛化。利用深度学习模型的泛化能力，能够“学习”到哪些公式子结构更容易产生高收益。
搜索效率	效率极低。在极大的算子和特征组合空间中，很容易陷入局部最优解，且对噪音极为敏感。	效率极高。神经网络通过观察走过的路径（Trajectories）来构建全局概率图，有明确的方向感和泛化性。
历史信息的利用	只利用当前种群的信息，一旦优秀的公式被淘汰，往往需要很长时间才能再次演化出来。	神经网络的权重记录了所有见过的结构化信息，能够更聪明地在有希望的子空间进行探索。


来源：国金证券研究所

1.2 AlphaSAGE：GFlowNet 结合 RGCN 与多维度奖励用于因子挖掘

AlphaSAGE（全称：Structure-Aware Alpha Mining via Generative Flow Networks for Robust Exploration）是计算机顶会 ICLR2026 Poster 最新收录的前沿工作，由北京大学和正仁量化联合完成。GFlowNet 是 AlphaSAGE 的底层生成逻辑，在其基础上，加入了关系图卷积网络（Relational Graph Convolutional Network, RGCN）捕捉因子结构信息，并且设计了一个密集且多维度的奖励函数，不再仅仅依赖于最终的预测表现。



图表3: AlphaSAGE 模型结构图



来源: Structure-Aware Alpha Mining via Generative Flow Networks for Robust Exploration, 国金证券研究所

本报告将专注于 GFlowNet 原理，对 GFlowNet 模型本身进行改进，探究其基于日频和分钟频量价数据对 A 股因子挖掘效果。


1.3 什么是 GFlowNet (Generative Flow Networks, 生成流网络) ?

GFlowNet 是由深度学习先驱，图灵奖与诺奖得主 Yoshua Bengio 团队于 2023 年在计算机顶刊 JMLR 上发表的新型生成模型。它的核心思想是将对象的生成过程建模为图网络中的“水流”(Flow)过程。

GFlowNet 将生成对象的步骤映射到一个有向无环图 (DAG) 中：

- 状态 (State, s)：代表生成过程中的中间状态 (例如：当前搭建了一半的分子)。
- 动作 (Action)：图中的有向边。从状态 s 转移到状态 s' 表示执行了一个动作 (例如：给分子添加一个碳原子)。
- 源点 (Source, s_0)：所有生成的起点 (例如：空图或空序列)。
- 汇点 (Sinks/Terminal states, x)：最终生成的完整对象。在这里会计算对象的奖励 $R(x)$ 。
- 流 (Flow, F)：可以将其想象为管道中的水流。 $F(s)$ 表示流经状态 s 的总水量， $F(s \rightarrow s')$ 表示沿着边流动的量。


图表4: GFlowNet 基于 DAG 生成最终对象



来源: GFlowNet Foundations, 国金证券研究所



图表5: GFlowNet 迭代构建对象的过程



来源: GFlowNet Foundations, 国金证券研究所

与传统强化学习为了找到单一的最优解（最大化预期回报）不同，GFlowNet 的目标是进行多样化采样。它的核心任务是生成组合型对象（例如分子结构、图、代码等），并使得生成某个特定对象 x 的概率与其对应的奖励（Reward）成正比，即： $P(x) \propto R(x)$ 。

数学原理：流匹配（Flow Matching）。GFlowNet 的训练目标是让网络中的流量分布满足守恒定律（类似基尔霍夫电流定律）。如果要保证最终到达终止状态 x 的流量等于它的奖励 $R(x)$ ，网络中的每一个中间节点都必须满足流匹配条件（Flow Matching Condition）：

对于任意中间状态 s ，流入它的总流量必须等于流出它的总流量：

$$\sum_{s' \in \text{Parents}(s)} F(s' \rightarrow s) = \sum_{s'' \in \text{Children}(s)} F(s \rightarrow s'')$$

对于终止状态 x （汇点），流入它的总流量等于环境赋予它的奖励：

$$\sum_{s \in \text{Parents}(x)} F(s \rightarrow x) = R(x)$$

如果整个图的流量严格满足上述等式，那么从源点 s_0 出发的总流量（即配分函数 Z ）就等于所有终止状态奖励的总和： $Z = \sum_x R(x)$

策略提取。一旦我们通过神经网络学习到了每一条边上的流 $F(s \rightarrow s')$ （或者类似的能量函数），我们就可以定义一个前向生成策略（Forward Policy） P_F 。

在状态 s 下，选择动作前往 s' 的概率就是分配到那条边上的流量占流出总流量的比例：

$$P_F(s'|s) = \frac{F(s \rightarrow s')}{\sum_{s''} F(s \rightarrow s'')}$$

按照这个概率策略一步步从源点走到终止状态，最终生成状态 x 的概率 $P(x)$ 就会被数学证明严格等于 $\frac{R(x)}{Z}$ 。

训练方法。由于真实环境中的状态空间呈指数级爆炸，我们无法精确计算所有的流。因此，GFlowNet 会使用神经网络来参数化流 F 或策略 P_F ，并通过设定损失函数（Loss Function）来进行训练。常见的训练目标包括：

- **Flow Matching (FM) Objective:** 直接使得流入和流出的差值的平方最小化。为了计算这个 Loss，你必须在训练的每一步都找出 s 的所有父节点和子节点，并对它们的流进行求和。这在复杂的图结构中计算量巨大，甚至在某些动态空间中是不可行的。



• **Detailed Balance (DB) Objective:** 通过引入后向策略 (Backward Policy)，将流匹配条件转化为针对单条边的更严格但更容易局部优化的平衡条件。

• **Trajectory Balance (TB) Objective:** 这是目前最常用且最稳定的损失函数。它不关注单个节点，而是关注一条完整轨迹。它要求整条从源点到终点的路径的前向概率乘积、总流 Z 与该路径的后向概率乘积、最终奖励 $R(x)$ 之间保持平衡。

二、基于日频数据的因子挖掘与 RL 比较

2.1 训练目标与过程

结合实际与经过实验比较，我们在训练中不直接优化流守恒，而是用更稳定的 Trajectory Balance (TB) 目标：

$$\mathcal{L}_{TB} = \left(\log \frac{Z \prod_{t=1}^n P_F(s_t | s_{t-1})}{R(x) \prod_{t=1}^n P_B(s_{t-1} | s_t)} \right)^2$$

其中， Z 是一个可学习的标量参数，代表总流量（即所有可能状态奖励之和的估计值）； P_F 是前向策略，代表在状态 s_t 选择动作的概率（需要学习的神经网络）； P_B 是后向策略，代表反向拆解的概率（可学习或固定均匀）； $R(x)$ 是终止状态的奖励。

具体训练过程如下：

- 用当前前向策略 P_F 采样一条轨迹 $s_0 \rightarrow s_1 \rightarrow \dots \rightarrow x$
- 计算 $R(x)$ （评估因子 reward 指标）
- 计算 TB loss，反向传播更新 P_F 和 Z
- 重复

2.2 状态表示、表达式与算子设计

在状态表示与动作空间的设计上，状态表示由两部分构成，一是动作历史序列，对由 operator/window/feature 构成的表达式进行 Transformer encoding 处理；二是 3 个手工状态特征，分别为当前深度、已用算子比例、已用节点比例。

动作空间定义为扁平离散空间，具体包含三类可选操作：1) operator 为选算子，共设置 51 个，涵盖一元、时序一元、二元、时序二元以及截面算子；2) window 为给时序算子选窗口，共设置 5 个可选窗口；3) feature 为选叶子特征，数量根据具体设计灵活变化，动作空间总大小为三类操作数量之和。

同时，在每一步仅允许执行“语法合法+不超复杂度上限”的动作，其中初始步强制选择 op，不允许纯特征根；若当前节点等待窗口，则只能选择 window；其他情况下可选择 feature，且在不超限时可继续选择 op。

表达式以 ExprNode 树结构进行组织，同时构建交换律排序、双重 neg 折叠等简化方法，使得等价表达式更容易归一为同一字符串，有效降低缓存重复。



图表6：因子挖掘算子设计体系

大类	类别标识 (category)	输入元数 (arity)	是否需要窗口 (needs_window)	算子列表	数量
一元算子	unary	1	否	abs, neg, sign, log, inv, sqrt, signed_power2, signed_powe r3	8
一元时序算子	ts_unary	1	是	ts_mean, ts_std, ts_max, ts_min, ts_rank, ts_skew, ts_kurt , ts_median, ts_delay, ts_delta, ts_pct_change, ts_sum, ts _argmax, ts_argmin, ts_decay_linear, ts_var, ts_mad, ts_co unt, ts_ema, ts_wma, ts_slope, ts_rsquare, ts_residual, ts _quantile	24
二元算子	binary	2	否	add, sub, mul, div, max2, min2, greater, less	8
二元时序算子	ts_binary	2	是	ts_corr, ts_cov, ts_beta, ts_orth	4
截面算子	cs	1	否	cs_rank, cs_zscore, cs_demean, cs_scale, cs_normalize, cs_ winsorize, cs_truncate	7

来源：国金证券研究所

2.3 特征、奖励设计与其它设定

针对日频量价数据，我们给 GFlowNet 输入两套特征，第一套是原始 OHLCV（后复权）数据，第二套是对原始 OHLCV 进行无量纲相对特征处理后的数据，以此降低价格交易量水平与拆分复权尺度差异带来的干扰。

图表7：原始 OHLCV 无量纲相对特征列表

特征名	定义（按日、按股票）	含义/直觉	备注
ret_gap	open / pre_close - 1	隔夜跳空幅度	开盘相对昨收的缺口
ret_cc1	close / pre_close - 1	日收益（收盘到昨收）	最基础的 1 日收益
ret_co	close / open - 1	日内涨跌（开到收）	反映盘中方向
ret_hl	high / low - 1	日内振幅比率	高低价比值尺度，波动特征
ret_range	(high - low) / pre_close	归一化振幅	用昨收归一化，更可比
ret_body	(close - open) / pre_close	K 线实体大小	趋势强弱（实体越大越强）
ret_upper_shadow	(high - max(open, close)) / pre_close	上影线比例	冲高回落/上方抛压迹象
ret_lower_shadow	(min(open, close) - low) / pre_close	下影线比例	下探回升/下方承接迹象
ret_close_vwap	close / vwap - 1	收盘相对成交均价偏离	收盘强弱、尾盘定价偏差
ret_open_vwap	open / vwap - 1	开盘相对成交均价偏离	开盘相对全天成交重心位置
ret_vol_chg1	volume / delay(volume, 1) - 1	成交量日变化率	量能突增突减
ret_vol_chg5	volume / mean(volume, 5) - 1	成交量相对 5 日均量偏离	短期放量/缩量

来源：国金证券研究所

奖励设计方面，我们观察到一个现象，如果直接根据原始因子的 abs(IC) 或者多头收益作为模型训练的 reward，会造成最终筛选出的因子过分暴露在小市值风格上，从而导致对现有因子体系提升不大。因此，我们将因子的 reward 设定为市值中性化后的 abs(IC)。

在数据集划分上，训练集为 2005 年 1 月 1 日至 2017 年 12 月 31 日，测试集即模型样本外数据为 2018 年 1 月 1 日至 2025 年 12 月 31 日，因子评估调仓周期为 10 日，评估范围为全 A 市场，最终基于测试集进行因子筛选时，我们会限定入选因子与已入选因子 spearman 相关性低于 0.4。

2.4 与 PPO 强化学习的对比：低相关性优势显著

为了充分说明 GFlowNet 的优越性，我们也基于几乎相同的环境、状态空间与网络架构，实现了一个强化学习因子挖掘系统。该模型的网络架构为基于 Transformer 的 Actor-Critic 结构，其中 Actor 头即策略网络是一个多层感知机(MLP)，用于输出下一步选择各个动作（算子、特征、窗口）的概率分布(Logits)；Critic 头即价值网络是一个平行的 MLP，输出一个标量值，用于预测“按照当前已经构建的公式骨架，最终能得到多高的 Alpha





收益”。

模型的核心算法为 PPO(Proximal Policy Optimization)，其中价值损失(Value Loss)使用均方误差(MSE)来衡量 Critic 预测的状态价值 $V(s)$ 与实际回报(Returns)之间的差距，有助于 Critic 更准确地评估当前公式的潜力；熵奖励(Entropy Bonus)通过引入策略的熵 $-\sum p \log p$ 作为奖励项，鼓励模型在早期探索不同的数学符号和特征，防止过早收敛到次优的公式上。

从训练过程的对比来看，强化学习的 batch 平均 reward 上升更快，GFlowNet 则呈现缓慢波动上升的态势，从表面上看似乎 RL 更具优势；在损失函数方面，强化学习呈现上升趋势，主要是因为熵项与轨迹长度的上升导致，并非训练出现问题。

图表8：强化学习损失函数与 batch 平均 reward

图表9：GFlowNet 损失函数与 batch 平均 reward





来源：Wind，国金证券研究所

来源：Wind，国金证券研究所

从 batch 内因子相关性角度出发，强化学习出现了非常明显的问题，因子对之间 spearman 相关性的中位数急速上升为 1，也就是说最后生成的因子有一大半都是完全相同的，模型失去实用价值；反观 GFlowNet，batch 内相关性水平一直保持稳定，没有明显的上升趋势，中位数仅不到 0.04，多样性优势显著。

图表10：强化学习 batch 内相关性水平

图表11：GFlowNet batch 内相关性水平



来源：Wind，国金证券研究所

来源：Wind，国金证券研究所

针对熵奖励为何不能使 RL 找到多样性的解这一问题，我们进一步分析，熵奖励(Entropy Bonus)通过引入策略的熵 $-\sum p \log p$ 作为奖励项，鼓励模型在早期探索不同的数学符号和特征，防止过早收敛到次优的公式上，类似的 Epsilon-greedy 同样也是引入了探索机制。

但对于 RL 来说，探索机制的引入只是为了防止模型塌缩在局部最优解，只是一个训练的手段，它的核心目标还是要找到最好的那个因子，模型一旦开始收敛，就会塌缩在一个核心解；而 GFlowNet 的目标本身就是要学会整个好解的分布，多样性就是它的目标，收敛后策略仍然会保持多样性。



2.5 日频数据 GFlowNet 因子挖掘效果


以 2018-2025 年为因子检验区间，观察基于原始 OHLCV 挖掘单因子表现，其整体表现良好，IC 均值的中位数达到 4.54%，最大值达到 8.56%，多头超额表现尚可，中位数为 3.47%。

图表12：基于原始 OHLCV 挖掘因子 IC 均值等统计指标

	mean	50%	75%	max
ic_mean	4.75%	4.54%	6.37%	8.56%
ic_ir	0.48	0.45	0.62	1.59
long_excret	3.30%	3.47%	7.37%	22.31%
long_sharpe	0.56	0.57	0.74	1.18
ls_ret	25.58%	27.10%	33.65%	65.65%
ls_sharpe	1.87	1.83	2.68	5.88


来源：Wind，国金证券研究所

图表13：基于原始 OHLCV 挖掘因子 IC 分布



来源：Wind，国金证券研究所

图表14：基于原始 OHLCV 挖掘因子 ICIR 分布



来源：Wind，国金证券研究所

对因子之间相关性的绝对值进行统计，发现相关性不高，截面和时序的均值均在 20%以下，后续进行因子合成，增益会比较明显。


图表15：基于原始 OHLCV 挖掘因子截面时序相关性统计指标

	均值	最小值	中位数	最大值
截面相关性	15.73%	0.03%	13.74%	74.79%
时序相关性	19.24%	0.06%	17.43%	71.95%


来源：Wind，国金证券研究所



图表16：基于原始 OHLCV 挖掘因子截面相关性



图表17：基于原始 OHLCV 挖掘因子时序相关性



来源：Wind，国金证券研究所

来源：Wind，国金证券研究所

因子长度与复杂度控制在较小水平，平均长度为 7.22，较长的因子占比不高，因此相对是具有一定可解释意义的。

图表18：基于原始 OHLCV 挖掘因子举例

因子表达式	IC	ICIR	Long_Excret	表达式长度
<code>ts_var(cs_demean(log(volume)), 10)</code>	-0.07	-0.92	0.18	5
<code>cs_normalize(ts_max(ts_pct_change(volume, 10), 20))</code>	-0.06	-0.60	0.16	6
<code>cs_winsorize(div(sqrt(open), mul(low, volume)))</code>	0.04	0.29	0.15	7
<code>sign(ts_min(cs_normalize(vwap), 60))</code>	-0.01	-0.04	0.15	5
<code>greater(ts_min(ts_cov(volume, vwap, 5), 10), abs(ts_delay(open, 40)))</code>	-0.04	-0.31	0.15	11

来源：Wind，国金证券研究所


图表19：基于原始 OHLCV 挖掘因子复杂度分布统计数据

	mean	min	50%	max
max_depth	2.92	2	3	3
op_count	3.64	2	3	7
leaf_count	3.58	2	3	8
complexity_len	7.22	4	7	14

来源：Wind，国金证券研究所



图表20: 基于原始 OHLCV 挖掘因子长度分布



来源: Wind, 国金证券研究所


基于相对特征挖掘的单因子表现相对原始特征更好，IC 均值的中位数达到 6.17%，最大值也达到了 9.40%，多头超额表现也更好，中位数为 4.75%，因子相关性和复杂度受同样的规则约束，因此也都保持在较低的水平。

图表21: 基于相对特征挖掘因子 IC 均值等统计指标

	mean	50%	75%	max
ic_mean	6.05%	6.17%	7.44%	9.40%
ic_ir	0.57	0.58	0.66	1.06
long_excret	4.08%	4.75%	8.82%	19.88%
long_sharpe	0.57	0.62	0.80	1.16
ls_ret	35.18%	33.90%	43.87%	72.60%
ls_sharpe	2.41	2.42	3.00	7.42


来源: Wind, 国金证券研究所

图表22: 基于相对特征挖掘因子 IC 分布



来源: Wind, 国金证券研究所

图表23: 基于相对特征挖掘因子 ICIR 分布



来源: Wind, 国金证券研究所

三、基于分钟频数据的因子挖掘

3.1 分钟频数据 GFlowNet 因子挖掘效果

对于分钟数据挖掘因子，本报告采取简易处理方法：首先主要基于价格动量、波动、价位



关系等 40 个指标，将日内分钟数据降为日频特征，；后续复用日频挖掘框架，基于该 40 个特征进行搜索。

图表24：基于分钟量价数据构造的日频特征列表

特征	定义	可能对应信号
amihud_intraday	日内 Amihud 非流动性 ($ ret /成交额$)	流动性冲击、冲击成本；高值常对应后续回撤或风险溢价
close_position	收盘价在当日高低区间的位置($close-low)/(high-low$)	收盘强弱、尾盘买卖压
closing_strength	尾盘收益或尾盘相对全天的强度	尾盘动量/资金抢收盘
gap_fill_ratio	开盘跳空被回补比例	均值回归 vs 趋势延续
high_low_ratio	日内高低价值比或振幅归一化	振幅强弱、波动状态切换
intraday_autocorr1	日内收益一阶自相关	短周期动量（正）或反转（负）
intraday_r2	时间-价格趋势回归的 (R^2)	趋势“线性度/稳定度”
intraday_trend	日内趋势斜率（回归 slope）	单边趋势方向与强度
kyle_lambda	Kyle 冲击系数（价格变动/净成交）	价格冲击敏感度、流动性风险
max_drawdown	日内最大回撤	脆弱性、下行尾部风险
max_ret_timing	最大收益出现的时间位置（早/中/晚）	行情节奏信息（开盘冲/尾盘拉）
max_runup	日内最大上行区间涨幅	上冲能力、短线情绪
momentum_concentration	收益是否集中在少数时段	事件驱动/脉冲式动量
opening_strength	开盘阶段收益强度	开盘定价偏差、早盘资金方向
price_impact_asym	上涨与下跌方向冲击不对称	买卖盘不平衡、隐含压力方向
realized_kurt	日内实现峰度	跳跃/尖峰风险
realized_skew	日内实现偏度	上下行不对称风险偏好
realized_vol	日内实现波动率	总体风险水平
realized_vol_afternoon	午后实现波动率	午后不确定性/消息敏感性
realized_vol_morning	上午实现波动率	开盘阶段风险释放
ret_afternoon	午后收益率	午后趋势或反转
ret_first15	开盘后 15 分钟收益	开盘冲击、短线动量
ret_first30	开盘后 30 分钟收益	早盘方向确认程度
ret_first5	开盘后 5 分钟收益	最短周期资金抢跑/噪声
ret_last15	收盘前 15 分钟收益	尾盘资金行为、收盘博弈
ret_last30	收盘前 30 分钟收益	尾盘趋势延续/对冲需求
ret_last5	收盘前 5 分钟收益	收盘撮合前抢单效应
ret_mid	盘中时段收益（非开非收）	中段趋势质量
ret_morning	上午总收益	早盘主导方向
reversal_intensity	日内反转强度（高频反转幅度）	均值回归强弱、噪声交易
rv_down_up_ratio	下行波动/上行波动比	恐慌偏向、下行风险占比
smart_money_flow	“聪明钱”流入代理（价量/大单加权）	机构方向、信息型交易
vol_concentration	成交量在时段上的集中度	交易拥挤、流动性时段性
vol_first15_ratio	前 15 分钟成交量占比	开盘活跃度、信息到达速度
vol_kurt	成交量分布峰度	成交脉冲/异常放量
vol_last15_ratio	后 15 分钟成交量占比	尾盘博弈强度
vol_morning_ratio	上午成交量占比	交易是否“前置”
vol_return_corr	成交量与收益相关性	放量上涨/放量下跌结构
vol_skew	成交量分布偏度	放量方向不对称
vwap_close_dev	收盘价相对 VWAP 偏离	收盘高估/低估、次日回归或延续

来源：国金证券研究所




基于分钟频构造特征挖掘的单因子表现较好，IC 均值的中位数达到 5.83%，最大值达到 9.46%。多头超额表现相较日频挖掘因子有明显提升，中位数为 7.43%。因子相关性和复杂度受同样的规则约束，因此也都保持在较低的水平。

图表25：基于分钟频构造特征挖掘因子 IC 均值等统计指标

	mean	50%	75%	max
ic_mean	5.66%	5.83%	7.04%	9.46%
ic_ir	0.55	0.57	0.67	1.26
long_excret	7.52%	7.43%	14.39%	29.15%
long_sharpe	0.71	0.74	1.04	1.39
ls_ret	39.40%	36.34%	46.62%	153.23%
ls_sharpe	2.81	2.77	3.40	8.95


来源：Wind，国金证券研究所

图表26：基于分钟频构造特征挖掘因子 IC 分布



来源：Wind，国金证券研究所

图表27：基于分钟频构造特征挖掘因子 ICIR 分布



来源：Wind，国金证券研究所

3.2 GFlowNet 挖掘因子等权合成效果

将挖掘出的因子按照因子方向等权合成，基于相对特征挖掘出的因子收益情况比较一般，基于分钟频数据构造特征挖掘的因子 IC 和多空收益较好。


图表28：GFlowNet 挖掘因子等权合成统计指标

	RankIC	ICIR	多头年化 ICT 超额收益 率	多头 Sharpe 比 率	多头信息 比率	多头超额 最大回撤	多空年化 收益率	多空波动 率	多空 Sharpe 比 率	多空最大 回撤	
raw	10.83%	0.81	11.16	17.35%	1.08	2.05	20.83%	88.67%	0.17	5.16	23.22%
relative	11.64%	0.82	11.28	10.22%	0.89	1.15	21.59%	84.51%	0.22	3.91	25.47%
min_feature	12.25%	0.85	11.75	16.08%	1.16	1.85	18.17%	109.12%	0.19	5.84	14.70%

来源：Wind，国金证券研究所




图表29: GFlowNet 挖掘因子等权合成超额净值



来源: Wind, 国金证券研究所

在风险暴露方面，单因子为对市值进行中性化后的因子值，合成之后，小市值和低波风格暴露依旧比较明显，基于相对特征挖掘的因子小市值暴露较低。


图表30: GFlowNet 基于原始 OHLCV 挖掘因子截面 Barra 相关性



来源: Wind, 国金证券研究所




图表31: GFlowNet 基于相对特征挖掘因子截面 Barra 相关性



来源: Wind, 国金证券研究所

图表32: GFlowNet 基于分钟频构造特征挖掘因子截面 Barra 相关性




来源: Wind, 国金证券研究所

从多头暴露来看，中小市值的多头暴露比较明显，同时等权合成因子具有明显的价值风格暴露。




图表33: GFlowNet 基于原始 OHLCV 挖掘因子多头暴露




来源: Wind, 国金证券研究所

图表34: GFlowNet 基于相对特征挖掘因子多头暴露



来源: Wind, 国金证券研究所

图表35: GFlowNet 基于分钟频构造特征挖掘因子多头暴露



来源: Wind, 国金证券研究所

四、对现有 AI 模型的提升与指增策略

在前期工作《基于 Mamba2 模型的端到端选股框架》中，我们引入了新的 Mamba 模型进行深度学习建模，本报告在 GRU 和 Mamba 的基础上，添加 GFlowNet 挖掘出的 150 个因子，可以发现几乎所有指标都有一定的提升。




图表36: GRU+Mamba+GFlowNet 全 A 统计指标

	RankIC	ICIR	多头年化 ICT 超额收益 率	多头 Sharpe 比率	多头信息 比率	多头超额 最大回撤	多空年化 收益率	多空波动 率	多空 Sharpe 比率	多空最大 回撤	
gru_mamba_lgbm	13.52%	1.27	17.52	31.95%	1.61	3.83	8.11%	162.36%	0.16	9.97	14.89%
gru_mamba_gflown et_lgbm	13.67%	1.27	17.52	32.88%	1.63	3.87	7.83%	166.31%	0.16	10.21	14.42%

来源: Wind, 国金证券研究所

图表37: GRU+Mamba+GFlowNet 全 A 多头超额收益率



来源: Wind, 国金证券研究所


图表38: 宽基指数增强统计数据

统计指标	策略	沪深 300	策略	中证 500	策略	中证 1000
年化收益率	11.39%	1.01%	14.40%	2.39%	21.39%	1.42%
年化波动率	18.89%	0.19	21.93%	0.22	24.86%	0.24
Sharpe 比率	0.60	0.05	0.66	0.11	0.86	0.06
最大回撤率	23.75%	45.60%	31.33%	41.81%	33.56%	46.71%
换手率 (10 日)	46.45%		47.41%		48.35%	
年化超额收益率	9.96%		11.16%		19.12%	
跟踪误差	5.34%		5.39%		6.38%	
信息比率	1.87		2.07		2.99	
超额最大回撤	7.72%		8.39%		8.83%	


来源: Wind, 国金证券研究所



图表39：沪深300增强净值




图表40：沪深300增强分年度数据




来源：Wind，国金证券研究所

来源：Wind，国金证券研究所

图表41：中证500增强净值



图表42：中证500增强分年度数据




来源：Wind，国金证券研究所

来源：Wind，国金证券研究所

图表43：中证1000增强净值



图表44：中证1000增强分年度数据



来源：Wind，国金证券研究所

来源：Wind，国金证券研究所



总结

本报告系统验证了 GFlowNet 在自动化因子挖掘中的有效性与实用性。相比传统遗传规划和强化学习方法，GFlowNet 以流量守恒为训练目标，能够在搜索空间中生成与奖励成正比的多样化因子集合。实验表明，基于 PPO 的强化学习虽然训练初期收敛较快，但很快出现模式崩溃，batch 内因子相关性中位数升至 1；而 GFlowNet 生成的因子相关性中位数低于 0.04，多样性优势显著。在日频量价数据上，基于原始 OHLCV 挖掘的单因子 IC 均值中位数为 4.54%，基于相对特征处理后的因子 IC 均值中位数提升至 6.17%，且多头超额收益稳定。进一步将分钟数据降维为 40 个日内特征后，挖掘出的因子 IC 均值中位数达 5.83%，多头超额收益中位数达 7.43%，较日频因子显著改善。合成因子呈现合理的中小市值与价值风格暴露，并成功融入既有 Mamba2 与 GRU 选股框架，各项评价指标均获得一致提升。综上，GFlowNet 为量化因子挖掘提供了一种高效、稳健且可解释的自动化解决方案。

风险提示

- 1、以上结果通过历史数据统计、建模和测算完成，在政策、市场环境发生变化时模型存在时效的风险。
- 2、策略通过一定的假设通过历史数据回测得到，当交易成本提高或其他条件改变时，可能导致策略收益下降甚至出现亏损。



特别声明：

国金证券股份有限公司经中国证券监督管理委员会批准，已具备证券投资咨询业务资格。

本报告版权归“国金证券股份有限公司”（以下简称“国金证券”）所有，未经事先书面授权，任何机构和个人均不得以任何方式对本报告的任何部分制作任何形式的复制、转发、转载、引用、修改、仿制、刊发，或以任何侵犯本公司版权的其他方式使用。经过书面授权的引用、刊发，需注明出处为“国金证券股份有限公司”，且不得对本报告进行任何有悖原意的删节和修改。

本报告的产生基于国金证券及其研究人员认为可信的公开资料或实地调研资料，但国金证券及其研究人员对这些信息的准确性和完整性不作任何保证。本报告反映撰写研究人员的不同设想、见解及分析方法，故本报告所载观点可能与其他类似研究报告的观点及市场实际情况不一致，国金证券不对使用本报告所包含的材料产生的任何直接或间接损失或与此有关的其他任何损失承担任何责任。且本报告中的资料、意见、预测均反映报告初次公开发布时的判断，在不作事先通知的情况下，可能会随时调整，亦可因使用不同假设和标准、采用不同观点和分析方法而与国金证券其它业务部门、单位或附属机构在制作类似的其他材料时所给出的意见不同或者相反。

本报告仅为参考之用，在任何地区均不应被视为买卖任何证券、金融工具的要约或要约邀请。本报告提及的任何证券或金融工具均可能含有重大的风险，可能不易变卖以及不适合所有投资者。本报告所提及的证券或金融工具的价格、价值及收益可能会受汇率影响而波动。过往的业绩并不能代表未来的表现。

客户应当考虑到国金证券存在可能影响本报告客观性的利益冲突，而不应视本报告为作出投资决策的唯一因素。证券研究报告是用于服务具备专业知识的投资者和投资顾问的专业产品，使用时必须经专业人士进行解读。国金证券建议获取报告人员应考虑本报告的任何意见或建议是否符合其特定状况，以及（若有必要）咨询独立投资顾问。报告本身、报告中的信息或所表达意见也不构成投资、法律、会计或税务的最终操作建议，国金证券不就报告中的内容对最终操作建议做出任何担保，在任何时候均不构成对任何人的个人推荐。

在法律允许的情况下，国金证券的关联机构可能会持有报告中涉及的公司所发行的证券并进行交易，并可能为这些公司正在提供或争取提供多种金融服务。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布该研究报告的人员。国金证券并不因收件人收到本报告而视其为国金证券的客户。本报告对于收件人而言属高度机密，只有符合条件的收件人才能使用。根据《证券期货投资者适当性管理办法》，本报告仅供国金证券股份有限公司客户中风险评级高于C3级（含C3级）的投资者使用；本报告所包含的观点及建议并未考虑个别客户的特殊状况、目标或需要，不应被视为对特定客户关于特定证券或金融工具的建议或策略。对于本报告中提及的任何证券或金融工具，本报告的收件人须保持自身的独立判断。使用国金证券研究报告进行投资，遭受任何损失，国金证券不承担相关法律责任。

若国金证券以外的任何机构或个人发送本报告，则由该机构或个人为此发送行为承担全部责任。本报告不构成国金证券向发送本报告机构或个人的收件人提供投资建议，国金证券不为此承担任何责任。

此报告仅限于中国境内使用。国金证券版权所有，保留一切权利。

上海

电话：021-80234211

邮箱：researchsh@gjzq.com.cn

邮编：201204

地址：上海浦东新区芳甸路1088号

紫竹国际大厦5楼

北京

电话：010-85950438

邮箱：researchbj@gjzq.com.cn

邮编：100005

地址：北京市东城区建国门内大街26号

新闻大厦8层南侧

深圳

电话：0755-86695353

邮箱：researchsz@gjzq.com.cn

邮编：518000

地址：深圳市福田区金田路2028号皇岗商务中心

18楼1806



【小程序】
国金证券研究服务



【公众号】
国金证券研究